AI IMPACT ON JOBS 2030

การทำนายความเสี่ยงของอาชีพในยุค AI ด้วย MACHINE LEARNING

01

PROBLEM STATEMENT

- **Input → Task → Output:**
  - **Input:** ข้อมูลเงินเดือน, ประสบการณ์, ระดับการสัมผัส AI (AI Exposure), ความซ้ำซากของงาน (Routine Level)
  - **Task**: Multi-class Classification

- **Output:** Risk Category (Low, Medium, High Risk)

- **Why ML/DL is needed?:** ความเสี่ยงในการตกงานมีปัจจัยที่ซับซ้อนและมีความสัมพันธ์แบบไม่เป็นเส้นตรง (Non-linear) กฎเกณฑ์ปกติคำนวณไม่ได้

- **Success Metrics:** ใช้ Macro F1-Score เพื่อเน้นความยุติธรรมในการประเมิน (Fairness) มากกว่าแค่ความแม่นยำรวม

DATASET DESCRIPTION

02

Dataset Overview & Preprocessing Plan

- **Source**: ชุดข้อมูลจาก Kaggle (AI Impact on Jobs 2030)
- **Preprocessing Plan**: ลบค่าว่าง (Drop NA) และเข้ารหัสข้อมูลเชิงกลุ่ม (Label Encoding)
- **The Most Critical Step** (การแก้ Target Leakage) :
  - **ดรอปคอลัมน์** Automation_Probability ทิ้ง!
  - **เหตุผล**: คอลัมน์นี้คือ 'ข้อมูลเฉลย' หากนำไปเทรน AI จะได้ Accuracy 100% ซึ่งหลอกลวงและใช้งานจริงไม่ได้ (เพราะผู้ใช้ใหม่จะไม่มีค่านี้)

LITERATURE REVIEW

Related Works & The Kaggle Trap

- **Related Works:** งานวิจัยส่วนใหญ่บน Kaggle ที่ใช้ Dataset นี้ ทำผลลัพธ์ได้ **Accuracy 100%**
- **ปัญหา:** โมเดลเหล่านั้นตกหลุมพราง Data Leakage ทำให้ระบบไม่ได้เรียนรู้พฤติกรรมคนจริงๆ

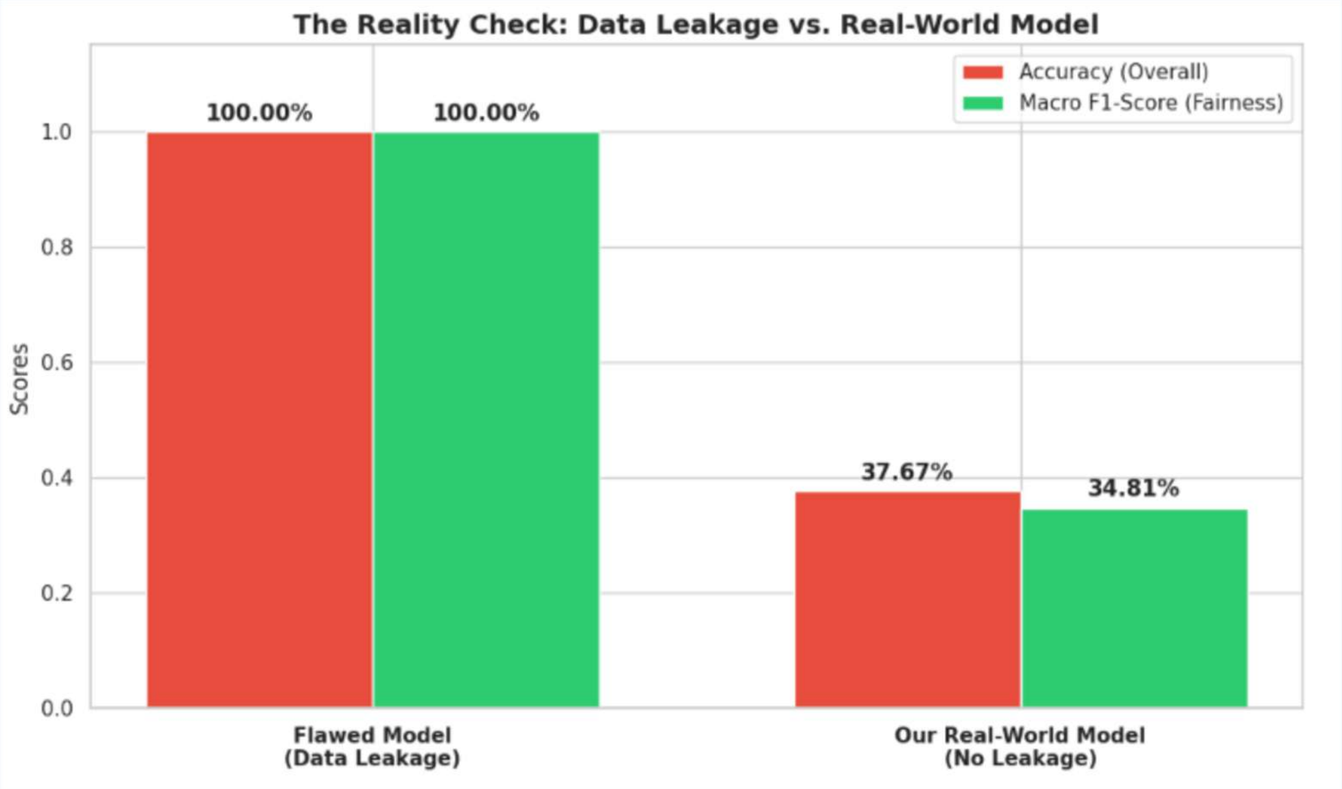

03

04 METHODS (MODEL DESIGN)

Balanced Random Forest Architecture

- **Model Selection:** เลือกใช้อัลกอริทึม Random Forest Classifier
- **Why this model?:** เป็น Ensemble Learning ที่รวบรวมการตัดสินใจจากต้นไม้หลายต้น ลดความผิดพลาด
- **Class Imbalance Handling:** ชุดข้อมูลมีกลุ่ม Medium เยอะเกินไป
    - ใช้เทคนิค class_weight='balanced' เพื่อบังคับให้โมเดลแฟร์กับชนกลุ่มน้อย (High Risk และ Low Risk)

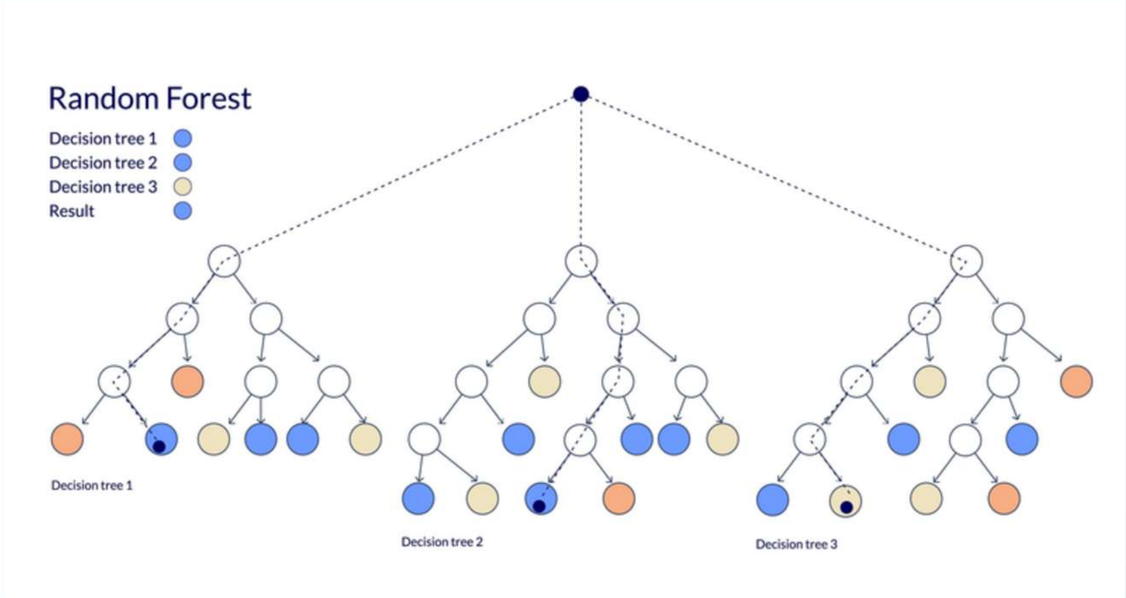

05

EXPERIMENT & HYPERPARAMETER TUNING

Hyperparameters Tuning (Pruning):ตัดแต่งกิ่งต้นไม้เพื่อบังคับให้จำเฉพาะแพทเทิร์นที่สาคัญ

- Baseline Model: เริ่มต้นด้วย Logistic Regression (พบปัญหา Bias เอนเอียงทายแต่ กลุ่ม Medium)
  - Experiment Variations: เปลี่ยนมาใช้ Random Forest แต่พบปัญหา Overfitting รุนแรง
  - Hyperparameters Tuning (Pruning): ตัดแต่งกิ่งต้นไม้เพื่อบังคับให้จำเฉพาะแพทเทิร์นที่สำคัญ

- n_estimators = 500 (จำนวนต้นไม้)
- max_depth = 10 (จำกัดความลึก)
- min_samples_leaf = 10 (ป้องกันการแตกกิ่งย่อยเกินไป)

06 ACCURACY/LOSS GRAPH (OVERCOMING OVERFITTING)

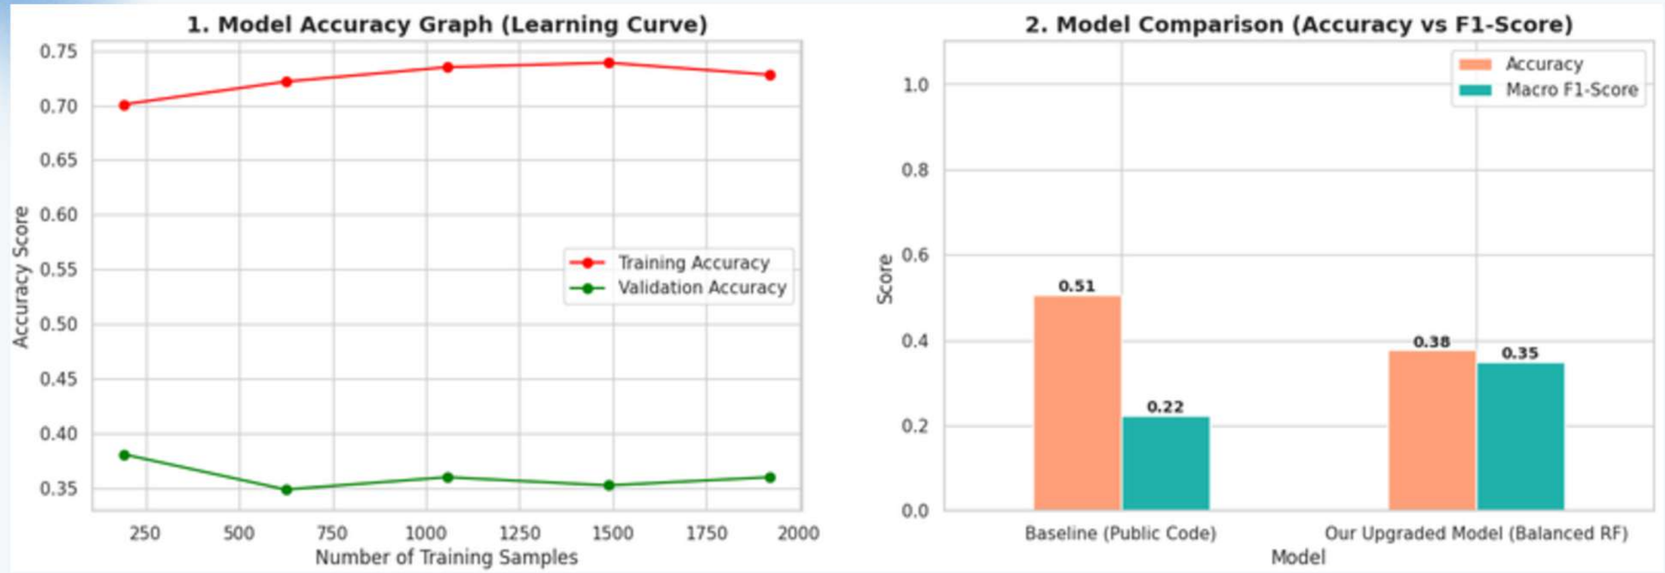

- หลังจากการทำ Pruning (max_depth=10) กราฟพิสูจน์ให้เห็นว่าเราแก้ปัญหา Overfitting สำเร็จ
- เส้น Training Score และ Validation Score วิ่งลู่เข้าหากัน (Converge) อย่างมี นัยสำคัญ

07 CONFUSION MATRIX & CLASS FAIRNESS

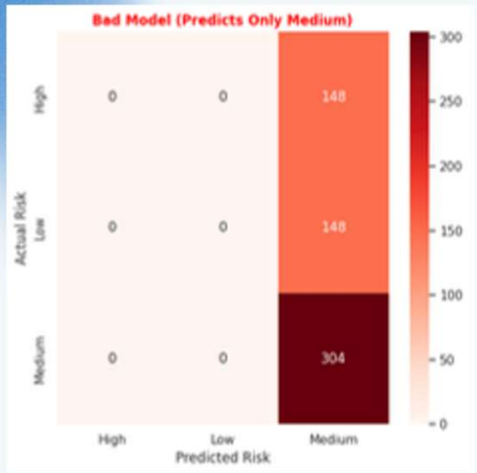

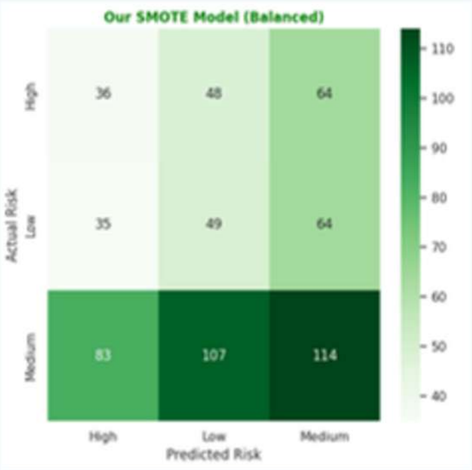

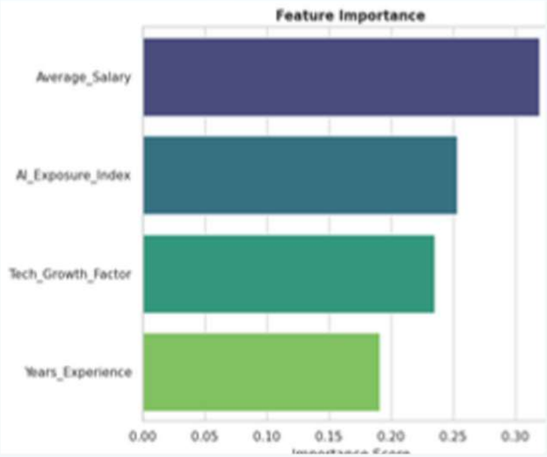

- Accuracy โดยรวมอยู่ที่ ~37% (เหนือกว่าเกณฑ์เดาสุ่มที่ 33%)
- เมื่อพิจารณา Confusion Matrix พบว่าโมเดลกระจายการทำนาย (True Positive) ได้ครอบคลุมทั้ง 3 ระดับ
- ค่า Macro F1-Score มีความสมดุล ยืนยันว่าโมเดลมีความยุติธรรม (Fairness) ไม่ทิ้งกลุ่ม เสี่ยงสูง

08 EARLY WARNING SYSTEM (DEPLOYMENT & BUSINESS LOGIC)

แนวคิดการใช้งานจริง

- นำโมเดลมาพัฒนาเป็น Early Warning System เพื่อแจ้งเตือนความเสี่ยงล่วงหน้า
- ใช้ Decision Threshold Tuning เพื่อกำหนดเกณฑ์การเตือน

Business Logic

- หากความน่าจะเป็นของ High Risk ≥ 30%
- ระบบจะ แจ้งเตือนทันทีว่า "High Risk 🔴"

```
# 3. ตัดสินใจและทำนายผล
probs = rf_model.predict_proba(sample)[0]
classes = target_encoder.inverse_transform(rf_model.classes_)
res_map = dict(zip(classes, probs))

if res_map.get('High', 0) > 0.30 and res_map.get('High', 0) > res_map.get('Low', 0) * 1.5:
    final_risk = "High"
elif res_map.get('Low', 0) > 0.30 and res_map.get('Low', 0) > res_map.get('High', 0) * 1.5:
    final_risk = "Low"
else:
    final_risk = "Medium"
```

เหตุผล

- ใช้แนวคิด Asymmetric Cost of Error
- การเตือนล่วงหน้าดีกว่าปล่อยให้เกิดความเสี่ยงโดยไม่แจ้งเตือน

09 GROUP MEMBER SIMULATION (REAL-WORLD IT ROLES)

การทดสอบ

- จำลองการใช้งานโมเดลด้วยข้อมูลสมาชิกกลุ่ม 4 คน
- นำข้อมูลจาก CSV แยกคนละไฟล์ เข้าโมเดลเพื่อประเมินความเสี่ยง

ผลลัพธ์

- สมาชิกทั้ง 4 คนถูกจัดอยู่ในกลุ่ม Low Risk 🟢

เหตุผล

- สายงาน Technical
- มี Routine Level ต่ำ
- ต้องใช้ Problem Solving และการคิดวิเคราะห์สูง

จึงมีความเสี่ยงต่ำต่อการถูกแทนที่ด้วย AI

10

INTERACTIVE DATA LOGGER ANALYSIS

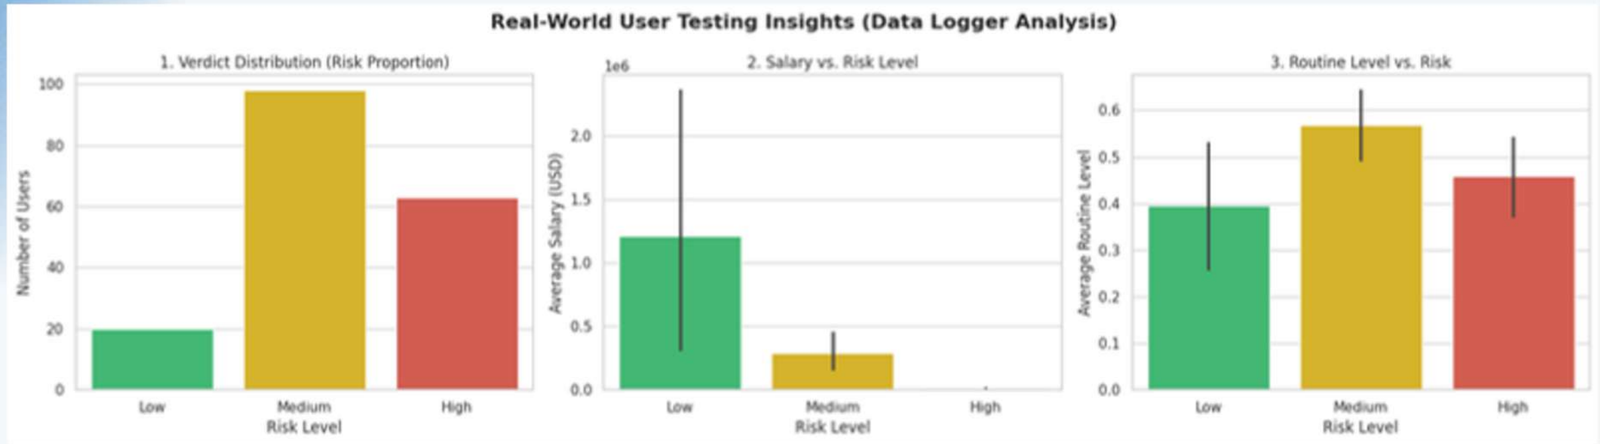

o ทดสอบระบบกับกลุ่มตัวอย่างวัยทำงานและนักศึกษา 181 คน
o Insight 1 (Salary): ผู้ที่ถูกจัดกลุ่ม Low Risk มีฐานรายได้สูงลิ่ว (ทักษะสูงสร้างมูลค่าเพิ่ม)
o Insight 2 (Routine Level): ยิ่งงานมีความซ้ำจากเจสูง ยิ่งถูกดันไปอยู่กลุ่มความเสี่ยงสูง (High Risk)

11

• CONCLUSION & PROJECT DELIVERABLES

- **Key Takeaways:** หลีกเลี่ยง Data Leakage คือหัวใจสำคัญของการสร้างโมเดลโลกความเป็นจริง

- "ทักษะการแก้ปัญหาที่ซับซ้อน คืองานที่ AI แย่งไปไม่ได้"

Summary : Machine Learning ช่วยให้เราเห็นแนวโน้มความเสี่ยงของอาชีพในปี 2030 ได้ ปัจจัยเรื่อง "เงินเดือน" ไม่ใช่เครื่องการันตีความมั่นคงเพียงอย่างเดียว ต้องดู "Tech Growth" ประกอบด้วย

THANK YOU